



Resumen Parte 2

Representación do Coñecemento e Razoamento Automático (Universidade da Coruña)

Tras plantearnos una manera de resolver problemas usando la lógica convencional se nos presenta una nueva forma, una que es más cercana al lenguaje normal, que contempla la existencia de escenarios con indeterminaciones e inexactitudes. En esta parte de la asignatura vemos cómo funciona la lógica difusa, cómo se puede usar para resolver problemas y las técnicas de razonamiento automático que se usan para resolverlos.

El contenido de esta parte empieza con los Métodos Difusos, ahí se introduce la lógica difusa, una forma de lógica en la que, como en la realidad, no se trabaja con valores exactos, sino con etiquetas del estilo: “mucho”, “poco”, “bastante”, que llamamos Conjuntos Difusos. Estos conjuntos poseen una función de grado de pertenencia (Que puede tomar muchas formas) que nos indica cuánto pertenece un elemento a un conjunto. Tras esta introducción se pasa a un repaso a la teoría de conjuntos, las propiedades que usaremos y las leyes de De Morgan. Se nos introduce aquí un nuevo concepto, el Núcleo de un conjunto difuso, el valor que hace que la función de grado de pertenencia dé como resultado 1. A continuación, se explica más en detalle las diferencias entre el razonamiento convencional y categórico y el difuso, cómo el razonamiento categórico es un caso particular del difuso, y otras formas de razonamiento que permiten definir el conocimiento.

Después de esto, se explica la estructura de los sistemas de lógica difusa, y la principal diferencia con la lógica clásica en la computación de la salida. Esto se ejemplifica con un caso práctico en el que se crea uno de estos sistemas en la herramienta para crear sistemas de lógica difusa de Matlab. Y para finalizar, se nos plantean otros métodos formales para representar el conocimiento donde se trata también con incertidumbres y permiten incluso incluir otros aspectos como el tiempo o que los hechos dejen de ser ciertos.

Tras esta introducción a la lógica difusa comenzamos a estudiar las técnicas de razonamiento en detalle con el razonamiento clásico. Aquí, el razonamiento está contemplado desde cuatro dominios, cada uno contenido en el siguiente. Los problemas se pueden contemplar en uno de estos dominios o en una combinación de los mismos.

El primero de ellos, el dominio categórico, está basado en la lógica clásica, sirve para problemas puramente simbólicos. Resolver problemas en este dominio requiere un conocimiento extenso de los mismos para definir las reglas que nos permitan llegar a una de tres posibles conclusiones (No hay solución, hay una solución o hay varias soluciones). Estas reglas, formadas por una serie de manifestaciones que dan lugar a interpretaciones, nos permiten generar una tabla donde relacionamos las manifestaciones con las interpretaciones posibles (que forman lo que se llama la Base Lógica Expandida, BLE) y, eliminar las relaciones que no cumplan todas las reglas para quedarnos con los posibles casos válidos del problema (la Base Lógica Reducida, BLR).

El segundo, el dominio estadístico, está basado en las probabilidades. Usaremos los conceptos de probabilidad total y probabilidad condicional y el teorema de Bayes, que permite obtener la probabilidad de una acción si se ha dado un efecto relacionado (y viceversa), y cómo generalizarlo para problemas de cualquier tamaño. Este planteamiento, usando las probabilidades condicionales, tiene el problema de que si incluimos nuevos elementos al problema, debemos recalcular las expresiones para contemplar este nuevo

elemento, pero permite darnos una medida de probabilidad de cada posible solución al problema. Para terminar, se plantea un problema en el que se aplican los métodos Categóricos y los Bayesianos para demostrar cómo se pueden combinar para alcanzar una solución.

El siguiente nivel, el razonamiento Cuasi-Estadístico es un concepto nuevo en el que se plantea el uso de la heurística y la estadística sin tomar muestras significativas para evitar los inconvenientes de los modelos anteriores. Aquí trabajamos con la probabilidad condicional subjetiva, las probabilidades de que ocurra una cosa si ocurre otra no está asegurada por un estudio estadístico amplio. De esta forma, introducimos nuevos conceptos, como la potencia evidencial, y reglas nuevas que debemos tener en cuenta, como que la suma de todas las probabilidades condicionales debe dar 1, y en caso contrario, se debe normalizar.

El modelo que usa este nivel de razonamiento es el modelo de factores de certidumbre de Shortliffe y Buchanan. Ahora mediremos la certeza de las respuestas por unas medidas de confianza, en vez de probabilidad (La medida de confianza creciente, MB y la de desconfianza creciente, MD), con las que podremos crear un factor de certidumbre (CF), que toma valores de -1 a 1 y permite saber la confianza que podemos depositar en una hipótesis. Por el rango de valores con los que trabaja, hay ciertas diferencias con respecto al rango que toman las probabilidades (de 0 a 1), por ejemplo, los CF de una hipótesis y su negación, no son los complementarios de la unidad, si no opuestos. No obstante, normalmente no trabajamos con una sola evidencia, por eso se nos plantea un método de combinar las evidencias para obtener el factor de certidumbre de una hipótesis relativa a varias de estas. En este caso, tenemos dos aproximaciones que, según las hipótesis contribuyan en un mismo sentido o en sentidos opuestos, permiten obtener el CF correspondiente. Cada una tiene algunas ventajas que no tiene la otra, por ejemplo, una permite la asociatividad pero no es directamente generalizable, o una es más sensible ante evidencias contradictorias en estados avanzados del razonamiento mientras que la otra no importa el orden para el cómputo. Tras esto, se explica la diferencia entre la imprecisión y la incertidumbre y cómo se propaga al combinar las evidencias. Finalmente aplicamos todo lo aprendido con un ejemplo de un problema resolviéndolo por el método de Shortliffe y Buchanan.

La cuarta y última capa reside en el razonamiento evidencial, donde trabajaremos con la Teoría Evidencial de Dempster y Shafer, un planteamiento muy complicado de entender pero con mucha utilidad para representar la falta del conocimiento. Aquí, tomamos la teoría de la probabilidad como un caso particular y tomamos algunas funciones del modelo de Shortliffe y Buchanan. Entre los términos importantes que usaremos tenemos el marco de discernimiento, compuesto por todas las hipótesis posibles del problema, en las que todas son mutuamente excluyentes y solo una es correcta. Y otro término importante es el elemento focal, un subconjunto de los elementos del marco que tiene la peculiaridad de que la suma de los valores resultantes de la función de asignación de verosimilitud de cada elemento debe dar 1 exactamente.

Tras esto, detallamos cómo se combinan las evidencias, en este modelo asumimos que son todas independientes, y debemos normalizar el resultado en el caso de que la intersección

de los elementos focales sea nula, para lo que tendremos que calcular un factor de normalización. Un ejemplo nos permite ver estas técnicas en funcionamiento y podemos comprobar que la suma de los nuevos valores siempre da 1 e, igual que en el nivel cuasi-estadístico, tenemos una medida que nos indica la confianza mínima y máxima que podemos depositar en un elemento focal a través de la credibilidad y plausibilidad, juntas forman un intervalo que representa la incertidumbre del elemento focal, cuánta confianza podemos depositar en este. Finalmente, en un ejemplo sobre la resolución de un asesinato, se pone a prueba este método y se explica paso a paso cómo se llega a encontrar al culpable con una seguridad considerable juntando las evidencias.

Para terminar el contenido de esta parte de la materia tenemos una aportación del profesor al campo en cuestión a través de un caso práctico en el que intentaremos diagnosticar una enfermedad de un paciente a partir de sus síntomas. Este método está basado en el modelo categórico y tiene el objetivo de reducir el coste computacional al trabajar con probabilidades tras obtener la BLR. De esta forma, podemos obtener una lista de reglas más sencillas en las que, si se da un síntoma, tenemos una probabilidad de que se dé cierta patología, y además, conocer la probabilidad de que se dé un síntoma dada una patología gracias a la probabilidad condicional.

En conclusión, con esta parte de la asignatura se plantea una nueva forma de entender el razonamiento, ya no nos apoyamos en certezas y reglas estrictas, podemos definir un problema, no con valores, si no con calificativos, en vez de decir “Juan mide 2 metros” decimos “Juan es alto”. Eso da mucho potencial para crear sistemas más parecidos al razonamiento humano pues tienden a comunicarse con términos indefinidos y no con valores exactos. Evidentemente estas indeterminaciones también conllevan a que haya un margen de error en los sistemas, pero eso creo que los hace más parecidos al razonamiento humano. Al fin y al cabo “Error es de humanos”.